

13 Agent 评估体系与常见陷阱

一句话概括这一章的核心矛盾

"评估分数好看"和"用户觉得好用"，是两件经常脱节的事。这一章要讲的不是"怎么算出一个分数"，而是"怎么设计一套真正能反映产品好坏的评估体系，同时避开那些让你被分数骗了的陷阱"。

Agent 评估该看哪些维度

单纯的"对话质量好不好"评估，对 Agent 是远远不够的——因为 Agent 的价值链条比一次问答长得多。一套完整的评估体系至少要覆盖四个维度：

Agent 评估体系

任务成功率
最终目标有没有达成

过程效率
用了多少步/多少Token/多长时间

安全与合规
有没有输出不合规的动作

用户体验
过程是否流畅、是否易懂、是否需要反复纠正

维度	常见指标	容易被忽视的坑
任务成功率	Pass@1、多次尝试成功率	只看"最终有没有做对"，忽略"是不是绕了很多不必要的弯路才做对"

维度	常见指标	容易被忽视的坑
过程效率	平均步数、平均Token消耗、平均延迟	效率指标必须结合成功率一起看——步数少但经常失败没有意义
安全与合规	越权操作率、敏感内容触发率	安全测试集覆盖不全，容易被"边界之外"的输入绕过
用户体验	用户满意度、人工纠正率、放弃率	这是最难自动化评估、但往往最重要的维度——线下Benchmark再好看，用户体验差照样留不住人

基准测试 (Benchmark) 方法论

- ###怎么构建一个靠谱的评估集
1. **覆盖真实分布，不是覆盖"容易测的场景"**: 很多团队的评估集是"随手想几个例子"拼出来的，容易偏向简单/典型场景，覆盖不到真实用户会遇到的边界情况。更靠谱的做法是从真实用户日志/历史case里采

样，保证分布贴近真实使用场景。

2. ****区分"能力测试"和"回归测试"**：******：能力测试集用来评估"新版本是否比旧版本更强"，回归测试集专门收集历史上出过问题的case，确保"修好的问题不会再犯"。这两套集合的构建目的不同，不要混用同一套数据。
3. **人工标注的黄金集，规模不需要很大但质量要高**：几百条经过认真人工标注、有明确对错标准的数据，比几千条粗糙自动生成的数据更有参考价值——这一点跟第12章讲的SFT标注数据质量原则是一致的。

常见陷阱：为什么评估结果好看，产品体验却差

陷阱一：评估指标和真实业务目标不一致

比如一个客服 Agent，评估集里用"是否给出了正确答案"来打分，但真实业务目标其实是"用户问题有没有真正被解决、有没有减少人工介入率"——如果评估指标和业务目标脱节，你优化出来的模型可能在评估集上分数很高，但对业务的实际帮助有限。

陷阱二：Benchmark 过拟合

如果团队长期盯着同一套评估集去调优（不管是调Prompt 还是训练模型），很容易出现“针对这套题变得很强，但换一批没见过的真实case表现明显下降”的情况——这跟机器学习里经典的过拟合问题是一回事。**解决方式：定期用全新的、没有被用来调优过的数据做“盲测”，交叉验证评估集本身的有效性。**

陷阱三：自动化评估的“裁判模型”本身有偏见


用一个LLM 去给另一个LLM 的输出打分（LLM-as-Judge）是目前很常见的自动化评估手段，效率很高，但裁判模型本身可能有系统性偏好（比如偏好更长的回答、偏好特定的表达风格），导致评分结果系统性偏离真实质量。**解决方式：抽样用人工评估去校准裁判模型的评分，定期检查两者的一致性。**

陷阱四：只测试“正常路径”，不测试“异常路径”

很多评估集只覆盖用户按预期方式提问的场景，不测试“用户输入模糊/矛盾/恶意/边界条件”时Agent

的表现。而这类异常路径恰恰是生产环境里最容易出问题、也最影响用户信任的地方。评估集应该专门划出一部分覆盖异常/边界case。

一套务实的评估节奏建议



评估不是一次性的"上线前测试"，是一个跟产品迭代同步的持续闭环——每一轮真实用户反馈都应该反哺进评估集，让评估集本身随着产品的真实使用场景一起进化。

产品经理清单

- ☐ 我的评估指标，跟真实业务目标是不是同一件事？还是评估指标好看了，业务指标未必跟着好看？
- ☐ 我有没有定期用"从没见过的新数据"做盲测，还是一直在同一套评估集上反复调优？
- ☐ 如果用了LLM-as-Judge自动化评估，有没有定期人工校准，确认裁判模型没有系统性偏见？
- ☐ 我的评估集里，异常/边界case的占比是多少？是

不是只覆盖了"正常提问"的场景?

Part 3 的核心能力篇到这里就结束了。我们从"怎么让Agent 记住重要的事"到"怎么管理有限的上下文"到"怎么和外部系统/其他Agent 通信"到"什么时候真的需要训练"再到"怎么评估效果", 补上了让 Agent 从"能跑Demo"到"能在生产里长期可靠运行"所需的全部关键能力。但还有一件事没讲——**Agent 能力越强, 一旦被攻击或失控造成的损失也越大**, 下一章我们讲Agent 安全与风险治理, 把护栏也一起补上。

章节自测 (5道单选, 答案见文末)

Q1. 一套完整的Agent评估体系至少要覆盖哪四个维度? A. 成本、速度、准确率、美观度 B. 任务成功率、过程效率、安全与合规、用户体验 C. 代码质量、文档完整度、Star数、下载量 D. 只需要任务成功率一个维度

Q2. "Benchmark过拟合"指的是什么现象? A. 模型参数太多 B. 长期盯着同一套评估集调优, 换一批没见过的真实case表现明显下降 C. 评估集太大 D. 训练数据不足

Q3. 用LLM-as-Judge做自动化评估的风险是什么? A. 成本太高 B. 裁判模型本身可能有系统性偏

好，导致评分系统性偏离真实质量 C. 速度太慢 D. 无法自动化

Q4. 构建评估集时，"能力测试集"和"回归测试集"的区别是什么？ A. 没有区别 B. 能力测试集评估新版本是否更强，回归测试集专门收集历史问题case确保不再犯 C. 回归测试集更大 D. 能力测试集不需要标注

Q5. 文中强调评估应该是什么性质的工作？ A. 一次性的上线前测试 B. 跟产品迭代同步的持续闭环，真实用户反馈应该反哺进评估集 C. 与产品迭代无关 D. 只需要做一次

► [点击查看参考答案](#)