


13 Agentic RL 产品经理版：SFT → GRPO，什么时候真的需要训练

先回答最该问的问题：我到底需不需要训练模型

这一章最容易被误读成"教你怎么训练模型"，但产品经理最该建立的认知反而是相反方向的：**绝大多数Agent 产品需求，靠Prompt工程+工具设计就能解决，根本不需要走到训练这一步。**训练是成本最高、周期最长、风险最大的能力提升手段，应该是"用尽了更便宜的手段之后"的最后选择，不是起点。

提升Agent 能力的手段，按成本从低到高排列



决策原则：永远先把左边更便宜的手段用到极限，再考虑右边。
我见过不少团队一上来就想"要不

要训练一个专属模型", 但实际上换一个更精确的Prompt、或者把工具的返回结果格式改清楚, 问题就解决了大半。

SFT vs RL：两种训练分别解决什么问题

SFT (Supervised Fine-Tuning, 监督微调)

核心机制：用一批"输入→期望输出"的标注数据, 让模型直接学习模仿这些示例的风格/格式/领域知识。

适合解决的问题：

- 模型输出的**格式/风格**不符合你的业务要求 (比如需要特定的话术风格、特定的结构化输出格式), 且用Prompt 里给示例 (Few-shot) 效果不稳定
- 需要模型掌握**领域专属知识**, 且这些知识用检索增强 (RAG) 也覆盖不好 (比如需要模型内化一套复杂的领域判断逻辑, 而不只是查资料)

产品经理该知道的成本关键：SFT 的效果上限, 很大程度取决于标注数据的质量和数量——"垂直领域几百条高质量标注数据"往往

比"几千条粗糙数据"效果更好，数据质量是决定ROI 的关键变量。

RL（强化学习，从 RLHF 到 GRPO）

核心机制：不是简单模仿示例，而是让模型自己生成多个候选答案，通过一个"奖励信号"（Reward）告诉模型哪个更好，模型据此调整自己的决策倾向。GRPO（Group Relative Policy Optimization）是近年 Agentic RL 里常用的一种具体算法，核心思路是：对同一个问题生成一组候选回答，组内相对比较打分，而不需要单独训练一个复杂的价值网络——这让训练流程更简化、更适合Agent 这种"多步决策"场景。

适合解决的问题：

- 任务有**明确的、可自动计算的奖励信号**（比如"任务是否成功完成"、"代码是否通过测试"），而不需要人工逐条标注"应该怎么做"
- SFT 已经让模型学会了"基本套路"，但在**多步决策的最优策略选择**上还不够好（比如"什么时候该调用工具、什么时候该停止规划"这类决策，比单纯格式模仿更依赖"试错优化"）

产品经理该知道的成本关键：RL 训练的最大瓶颈往往不是算力，是**"怎么设计一个准确反映业务目标的奖励函数"**——奖励设计得


不好，模型会学会"钻奖励函数的漏洞"而不是真正解决问题（这是强化学习领域著名的Reward Hacking 问题）。

SFT→GRPO 训练闭环（产品经理理解版）



这条闭环里，**每一步都对应一次实际的资源投入决策**：SFT 阶段要不要标注更多数据、Reward 设计要不要更精细、GRPO 要跑几轮——产品经理不需要亲自写训练代码，但需要能判断"这一步的投入产出比划不划算"。

决策框架：我真的到了需要训练的阶段吗



产品经理清单

- ☐ 我是不是跳过了"优化 Prompt/工具设计"这个更便宜的手段，直接想着训练？
- ☐ 如果考虑SFT，我有没有评估获取高质量标注数据的真实成本和周期？
- ☐ 如果考虑RL，我能不能明确说出"奖励函数具体怎么计算"？说不清楚就说明还没准备好训练，先把任务目标量化清楚。
- ☐ 训练这条路径的预期投入（时间/算力/人力）和预期收益，有没有认真算过账，还是"感觉应该会更好"？

下一章，我们讲怎么给Agent 的表现"打分"——评估体系与常见陷阱，这是所有前面章节最终都要接受检验的一环。

章节自测（5道单选，答案见文末）

Q1. 提升Agent能力的手段中，成本最低的是什么？ A. 强化学习训练 B. Prompt工程 C. SFT微调 D. 重新训练基础模型

Q2. SFT最适合解决什么问题？ A. 多步决策的最优策略选择 B. 模型输出格式/风格不符合业务要求，或需内化领域专属知识 C. 实时数据检索 D. 降低推理成本

Q3. RL训练最大的瓶颈往往是什么？ A. 算力不足 B. 怎么设计一个准确反映业务目标的奖励函数，否则容易出现Reward Hacking C. 没有GPU D. 数据太多

Q4. 文中反复强调的决策原则是什么？ A. 一开始就应该训练模型 B. 永远先把更便宜的手段用到极限，再考虑训练 C. 训练比Prompt工程更划算 D. SFT一定优于RL

Q5. GRPO算法的核心思路是什么？ A. 单独训练一个复杂价值网络 B. 对同一问题生成一组候选回答，组内相对比较打分调整模型倾向 C. 不需要奖励信号 D. 只能用于单步任务

► [点击查看参考答案](#)