


22 Agent 产品的 AB 测试方法 论：给"会自主 决策"的产品做 实验

为什么传统 AB 测试方法论会在 Agent 产品上失灵

传统 AB 测试的成立前提是：同一个输入，在同一个版本下，大概率会得到相近的输出——这样你才能把"效果差异"干净地归因到"版本差异"上。Agent 产品打破了这个前提：同一句用户输入，同一个版本，两次调用可能走出两条完全不同的执行路径（工具调用顺序不同、中间推理步骤不同、甚至最终答案的措辞完全不同）。如果直接套用传统 AB 测试的统计方法，你会发现噪声大到快把真实的版本差异淹没——这不是样本量不够的问题，是"响应本身自带随机性"这个新变量没被建模进去。

Agent AB 测试要 解决的三个新问题



问题一：非确定性 ——看分布，不看单 次

对同一批 case，Agent 新旧版本各跑多次（不是跑一次就下结论），观察**成功率**的分布而不是某一次的结果。如果新版本平均成功率更高但方差也大得多（意味着"有时候很好、有时候很差"），这种"不稳定的提升"在真实产品里往往比"稳定但提升小"更危险——用户对不稳定体验的容忍度远低于对普通体验的容忍度。

问题二：单一指标不够——任务成功率 + 过程合规率双轨

一个 Agent 任务"结果对了"，不代表"过程对了"——它可能因为运气好绕过了一个本该拦截的风险动作，恰好没造成损失。反过来，"过程完全合规"也不代表"结果一定好"。AB 测试必须同时看两条线：

指标	衡量什么	常见坑
任务成功率	最终结果是否达成用户目标	只看这个会漏掉"侥幸走对但过程有风

指标	衡量什么	常见坑
		险"的 case
过程 合规率	执行路径是否遵守了预设的护栏 (权限范围/高风险动作确认/工具调用是否必要)	只看这个会忽略"过程规范但结果没用"的 形式主义
用户 满意度 (人工/ 隐式反 馈)	用户是否认可这次交互	容易被"回答得很自信但不对"的 case误导，需要配合任务成功率交叉验证
成本 效率	完成同样任务消耗的Token/ 调用次数/耗时	容易被忽略——新版本效果提升5%但成本翻倍，商业上未必划算

问题三：护栏指标
——效果提升不能拿
风险去换


这是 Agent AB 测试和传统产品 AB 测试最大的分野。传统产品做 AB 测试，"新版本转化率更高"基本就可以直接判定为赢；Agent 产品**必须多加一层判断——新版本的效果提升，有没有伴随着风险动作触发率、越权尝试率、幻觉率这些护栏指标的上升**。如果新版本任务成功率提升了 8%，但高风险动作绕过确认的比例也上升了，这不是一个能直接上线的"胜出版本"，而是一个需要先修复护栏才能上线的版本。**效果指标和护栏指标必须同时达标，任何一边不过线都不能算实验成功。**

实验设计要点： 从"单条消息"升级到"整个 Session"



Agent 任务经常是多轮的，如果按"单条消息"随机分组，同一个用户在完成一个任务的过程中可能被分到不同版本，数据会完全脏掉。**必须按 Session（一次完整的任务/对话）做分组**，确保同一个任务全程使用同一版本，评估口径也要相应从"这条回复好不好"升级为"这个任务整体有没有被高质量完成"。

决策框架：什么阶段该上线上AB测试，什么阶段该先做离线评估



产品经理清单

- ☐ 我的AB测试有没有对同一批case做多次重复采样，还是只跑了一次就下结论？
- ☐ 我的评估指标里有没有同时包含"效果指标"和"护栏指标"，两者是不是分开单独看，而不是合成一个笼统的总分？
- ☐ 我的实验分组是按单次请求还是按完整Session？如果任务是多轮的，按请求分组的数据基本不可信。
- ☐ 上线上AB测试之前，我有没有先做过离线评估，

确认新版本大概率没有明显的护栏风险？

小结

Agent 产品的实验方法论本质是在传统 AB 测试的地基上，**多打了两根桩**：一根应对"输出本身不确定"，一根应对"效果和风险必须分开看、不能相互抵消"。忽略这两点直接照搬传统方法论，得到的实验结论很可能是错的——"新版本效果更好"这个结论本身可能只是噪声，或者代价是风险指标的隐性上升。

下一章，我们从"怎么验证效果"进入"怎么让这个产品挣钱"——Agent 产品的商业化与定价模式。

章节自测（5道单选，答案见文末）

Q1. 传统AB测试方法论在Agent产品上失灵的根本原因是什么？ A. Agent产品用户少 B. 同一输入同一版本下，Agent的输出本身可能不同，打破了传统AB测试"效果差异可归因到版本差异"的前提 C. Agent产品没有版本概念 D. 服务器不稳定

Q2. 文中"双轨指标体系"指的是什么？ A. 只看任务成功率 B. 同时看任务成功率和过程合规率，因为结果对了不代表过程合规，反

之也一样 C. 只看用户满意度 D.
只看成本

Q3. 为什么Agent AB测试中"效果指标提升"不能单独作为上线依据?

A. 效果指标不重要 B. 必须同时确认护栏指标（风险动作触发率等）没有随之上升，效果和风险不能相互抵消 C. 只要效果好就该上线 D. 护栏指标不需要测量

Q4. 为什么Agent的AB测试实验分组要按Session而不是按单次请求?

A. 按请求分组更简单 B. 多轮任务如果按单次请求分组，同一用户完成任务过程中可能被分到不同版本，数据会脏掉 C. Session级别没有意义 D. 两者没有区别

Q5. 文中建议什么情况下才应该把新版本推上线上做AB测试?

A. 随时都可以直接上线测试 B. 先有离线评估基准，确认效果显著优于基线且护栏指标同步达标后，再小流量上线 C. 只要开发完成就上线 D. 不需要离线评估

► [点击查看参考答案](#)